

SELU + LeCun mantém o sinal vivo nas 48 camadas

Desafio 2: ativação e inicialização em redes profundas · GBC073, UFU

1 · $f = \text{SELU}$

$\text{selu}(x) = \lambda x$ se $x > 0$, e $\lambda \alpha(e^x - 1)$ se $x \leq 0$. Para $z \sim N(0, 1)$, $\mathbf{E}[f(z)^2] = 1$ (conferido por amostragem).

2 · $s^2 = 1 / \text{fan_in}$ (LeCun normal)

$\text{Var}(z') = \text{fan_in} \cdot s^2 \cdot \mathbf{E}[f(z)^2]$. Com $\mathbf{E}[f(z)^2] = 1$, basta $s^2 = 1/\text{fan_in}$ para o fator ser **1** em toda camada, preservando a variância. Viés zero.

3 · Última camada com desvio $\times 0,5$

Logits iniciais com variância 0,25: perda inicial próxima de $\ln 10$ e primeiros passos do SGD (lr 0,05, momento 0,9) mais suaves.

Resultado

O baseline ($\tanh + U(-0,05; 0,05)$) encolhe a variância a cada camada (fator $\approx 0,2$): em 48 camadas o sinal já é $\sim 10^{-33}$ e o gradiente não chega à primeira camada. Com **SELU + LeCun**, a variância fica em ≈ 1 nas 48 camadas — o sinal e o gradiente sobrevivem, sem BatchNorm e sem conexões residuais.