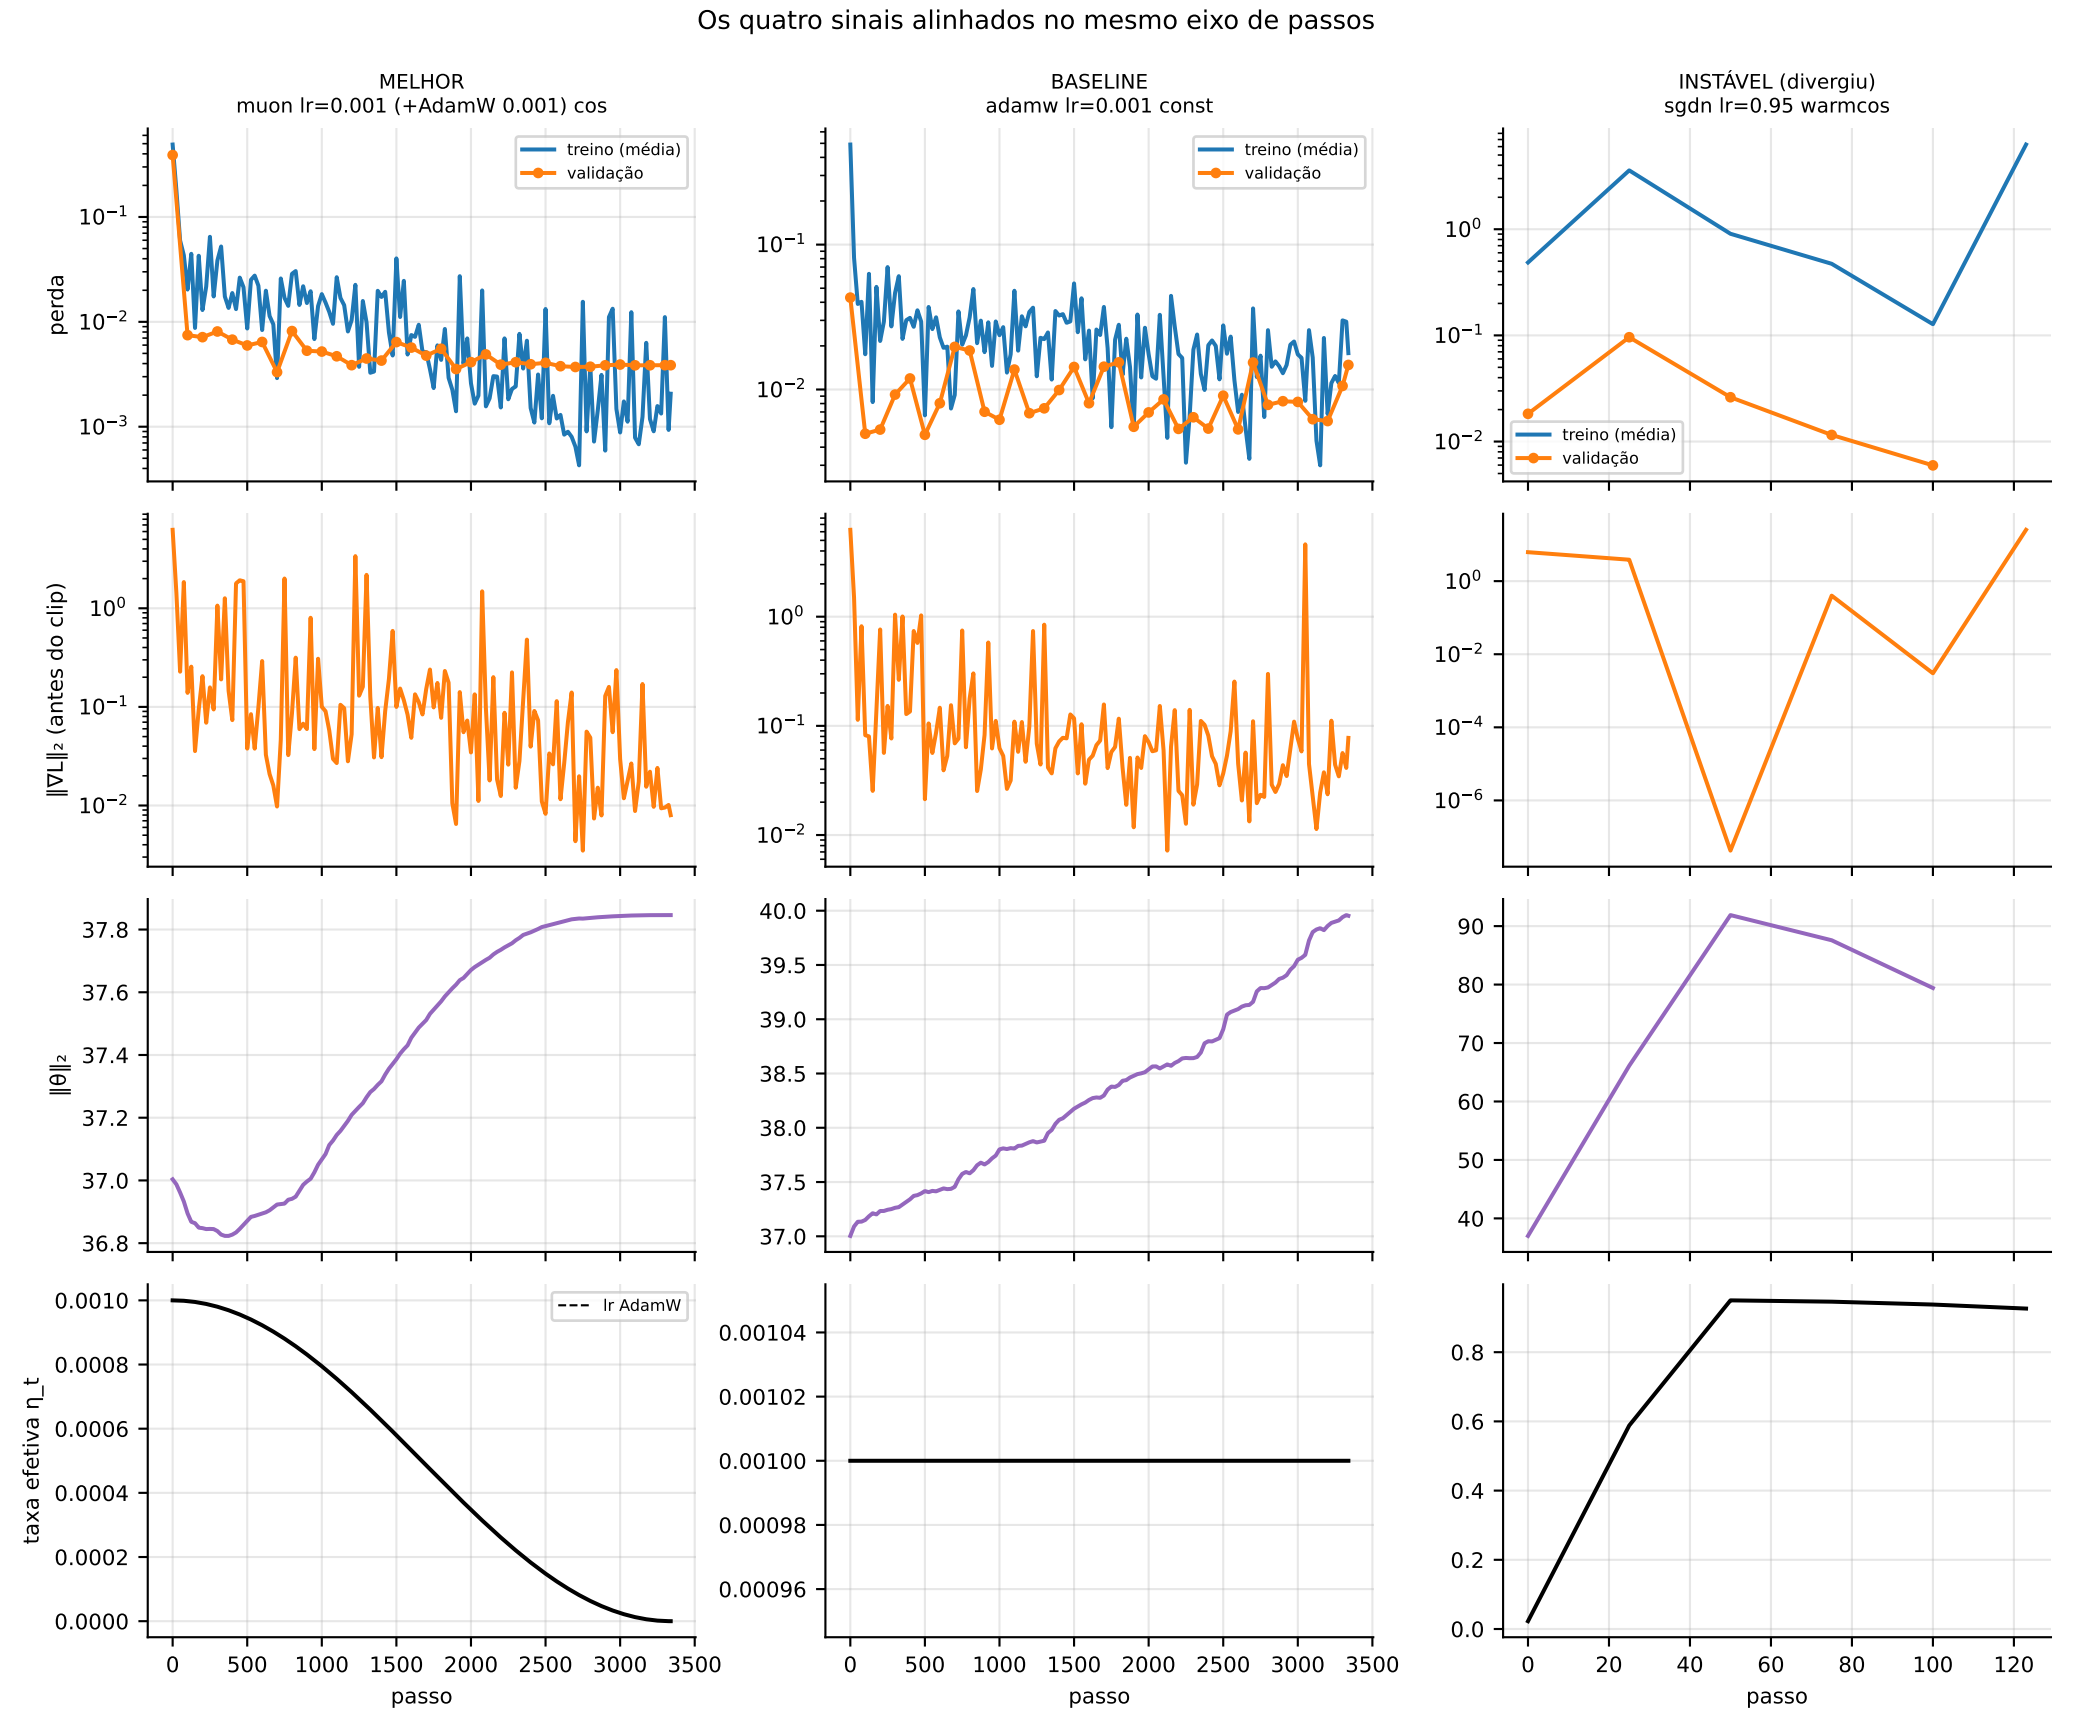
Os quatro sinais alinhados no mesmo eixo de passos
MELHOR
muon lr=0.001 (+AdamW 0.001) cos
BASELINE
adamw lr=0.001 const
INSTÁVEL (divergiu)
sgdn lr=0.95 warmcos
treino (média)
validação
perda
‖∇L‖₂ (antes do clip)
‖θ‖₂
taxa efetiva η_t
lr AdamW
passo

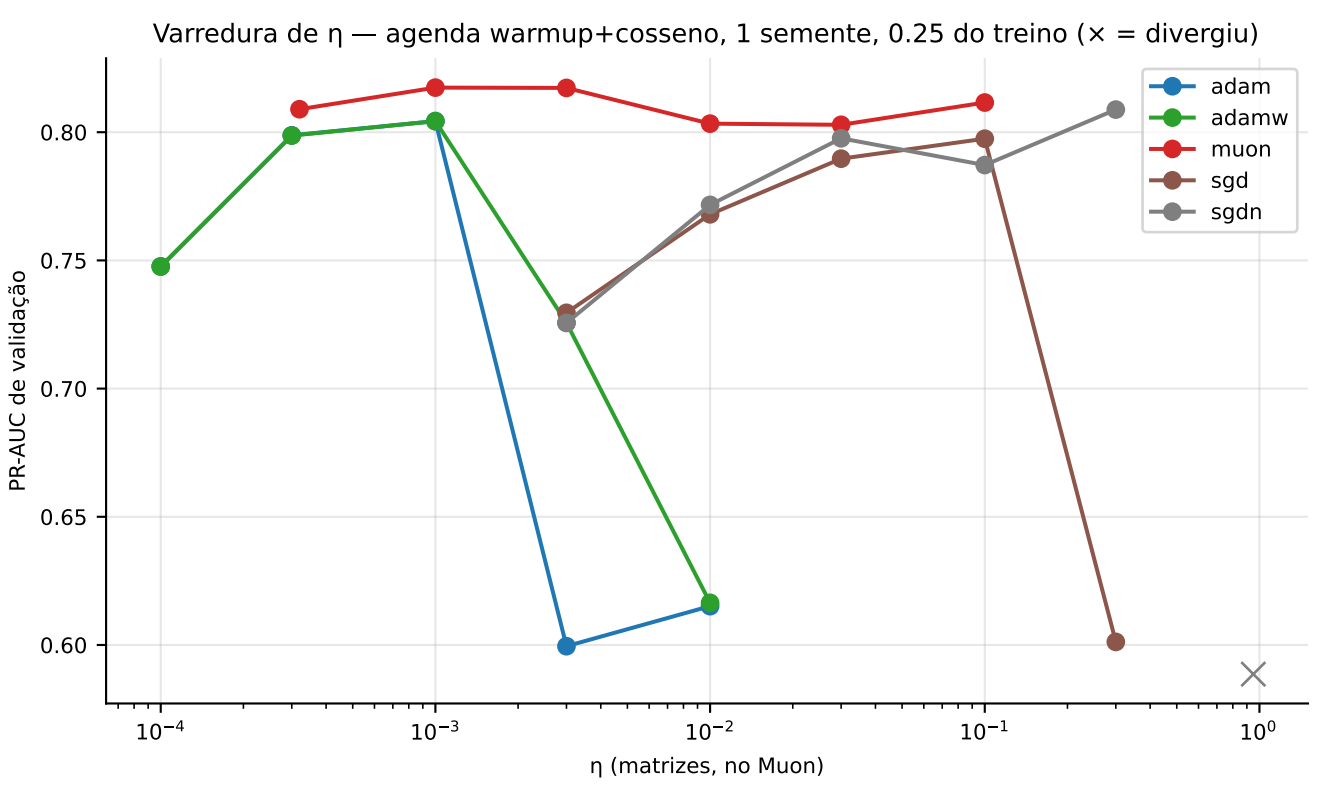
Varredura de η — agenda warmup+cosseno, 1 semente, 0.25 do treino (× = divergiu)
adam
adamw
muon
sgd
sgdn
PR-AUC de validação
0.80
0.75
0.70
0.65
0.60
10^{-4}
10^{-3}
10^{-2}
10^{-1}
10^{0}
η (matrizes, no Muon)

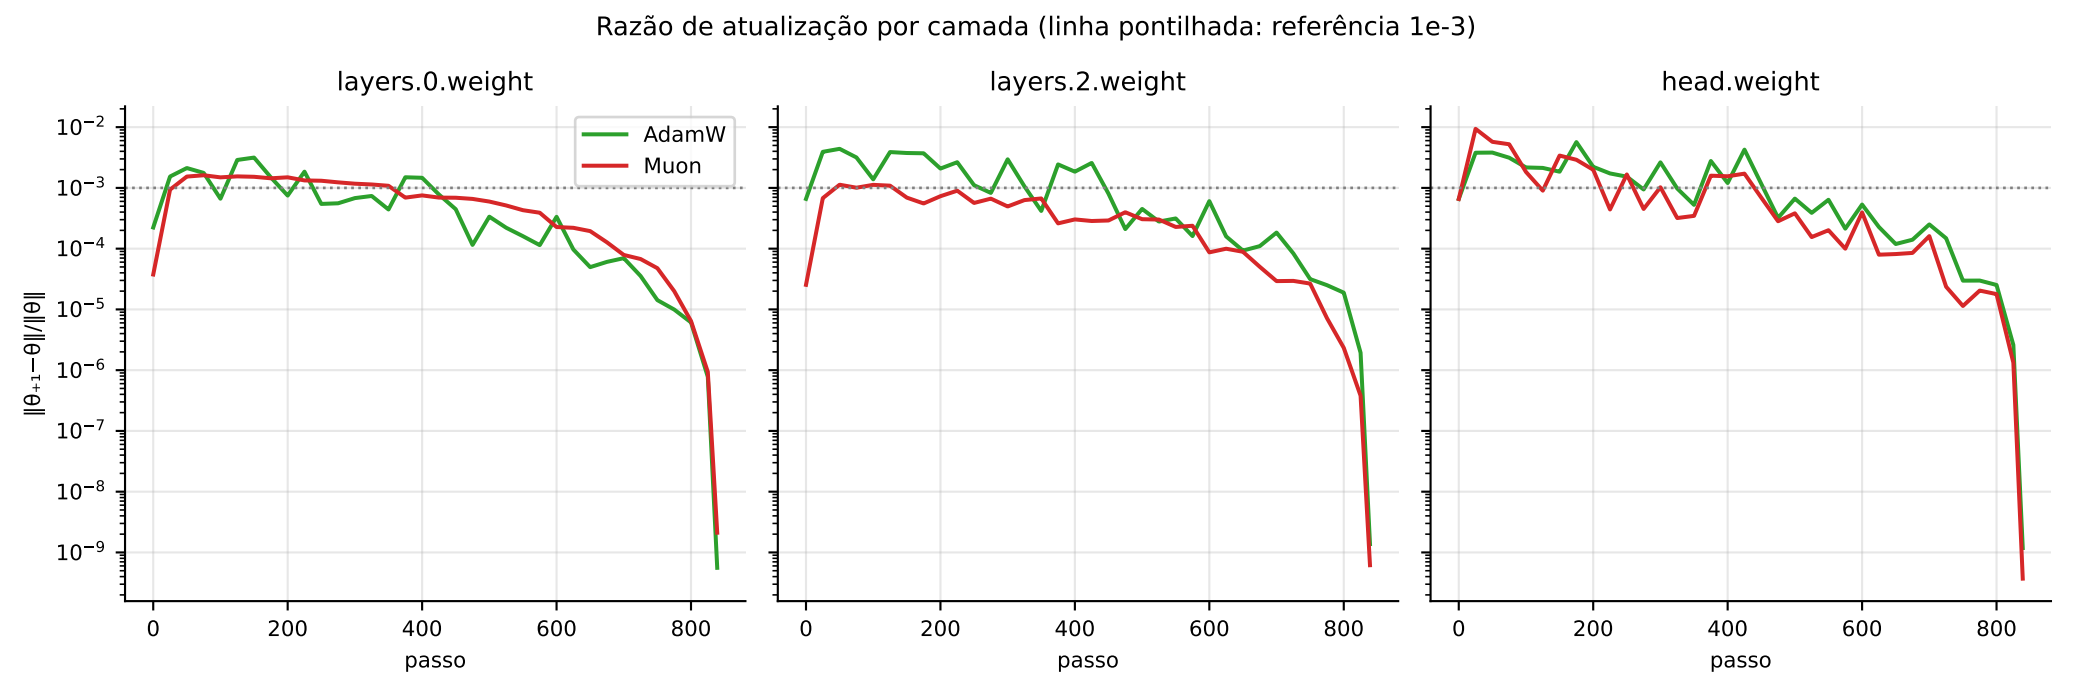
Razão de atualização por camada (linha pontilhada: referência 1e-3)
layers.0.weight
layers.2.weight
head.weight
AdamW
Muon
$\|\theta_{t+1} - \theta_t\| / \|\theta_t\|$
passo
passo
passo

Confirmação — dados completos (frac=1)

configuração	n sementes	PR-AUC val (média)	desvio
muon lr=0.001 (+AdamW 0.001) cos	3	0.7978	0.0114
muon lr=0.001 (+AdamW 0.001) warmcos	3	0.7950	0.0104
muon lr=0.001 (+AdamW 0.001) wsd	3	0.7788	0.0116
adamw lr=0.001 const	3	0.7284	0.0603